

Modelo Vetorial e BM25 na Coleção Cranfield

SCC0282 – Recuperação de Informação – Trabalho Prático 1

Leonardo D. Demore (15674786) Arthur Araujo (14651458)

Instituto de Ciências Matemáticas e de Computação (ICMC) – Universidade de São Paulo (USP), São Carlos

leodemore@usp.br, arthurhsilvaaraujo@usp.br

1 Introdução

Sistemas de Recuperação de Informação (RI) ordenam documentos de uma coleção segundo sua relevância estimada para uma consulta. Mesmo modelos clássicos, baseados apenas em sobreposição ponderada de termos, dependem de muitas decisões: como o texto é normalizado, como os termos são ponderados, como o comprimento dos documentos é tratado e como os parâmetros são calibrados. Entender o efeito de cada uma é o que permite explicar *por que* um sistema acerta ou erra uma consulta, além de medir a média.

O objetivo deste trabalho é implementar e avaliar dois modelos clássicos, o **Modelo Vetorial** (tf-idf com cosseno) e o **BM25**, sobre a coleção Cranfield. Comparamos quatro configurações de pré-processamento, analisamos as diferenças entre os modelos consulta a consulta, variamos os parâmetros k_1 e b do BM25, reformulamos consultas manualmente e investigamos erros concretos do ranking. A indexação, a ponderação, a busca e todas as métricas foram implementadas pelo grupo em Python; bibliotecas foram usadas apenas para leitura dos dados (ir_datasets), stopwords e stemming (nltk) e tabelas/gráficos (pandas, matplotlib).

2 Técnicas Utilizadas

2.1 Pré-processamento

Indexamos apenas o campo `text` de cada documento, que já contém o título em 1399 dos 1400 documentos (`author` e `bib` são metadados). A tokenização usa a expressão regular `[a-z0-9]+` após conversão para minúsculas. A remoção de stopwords (lista do NLTK para inglês) é feita antes do stemming de Porter: na ordem inversa, palavras como *does* virariam *doe* e escapariam da lista. As mesmas etapas são aplicadas às consultas. Comparamos quatro configurações: **nada**, **stopwords**, **stemming** e **stop+stem** (Tabela 1).

Tabela 1: Efeito do pré-processamento sobre a coleção.

Configuração	Vocabulário	Termos totais	Termos/doc
nada	7.471	226.526	161,8
stopwords	7.352	132.721	94,8
stemming	4.820	226.526	161,8
stop+stem	4.709	132.721	94,8

As duas etapas agem em eixos diferentes. A remoção de stopwords corta 41% dos tokens, mas só 119 termos do vocabulário, o que rende sobretudo *eficiência*. O stemming não altera o número de tokens, mas reduz o vocabulário em 35% ao unir variantes morfológicas (*pressure*, *pressures* → **pressur**), o que rende *revocação*. Como eliminam coisas diferentes, os efeitos se somam. Após o pré-processamento, os termos mais frequentes deixam de ser *the*, *of*, *and* e passam a ser **flow**, **pressur**, **number**, **boundari**, **layer**, o vocabulário técnico da aerodinâmica.

2.2 Modelo Vetorial

Documentos e consultas são vetores no espaço do vocabulário, com peso `ltc`:

$$w_{t,d} = (1 + \log_{10} \text{tf}_{t,d}) \cdot \log_{10} \frac{N}{\text{df}_t}, \quad \text{sim}(q, d) = \frac{\vec{q} \cdot \vec{d}}{\|\vec{q}\| \|\vec{d}\|},$$

em que $\text{tf}_{t,d}$ é a frequência do termo no documento, df_t o número de documentos que o contém e $N = 1400$. O logaritmo amortece repetições, o idf valoriza termos raros e a divisão pelas normas torna o score independente da escala dos vetores. Os pesos ficam num índice invertido (termo → {documento: peso}) com as normas pré-calculadas, de modo que o score só percorre os termos da consulta. Como verificação, um documento usado como consulta contra si mesmo obtém cosseno exatamente 1,0000.

O índice também mostra o ganho de eficiência das stopwords: o número médio de documentos com score não nulo por consulta é 1366,3 na configuração **nada** (basta um *the* em comum) e 730,8 com remoção de stopwords. O ranking quase não muda, pois o idf dessas palavras é ≈ 0 , mas sem a remoção percorre-se quase a coleção inteira.

2.3 BM25

O BM25 foi implementado explicitamente:

$$\text{BM25}(q, d) = \sum_{t \in q} \text{qt}_t \cdot \text{idf}_t \cdot \frac{\text{tf}_{t,d} (k_1 + 1)}{\text{tf}_{t,d} + k_1 (1 - b + b \frac{|d|}{\text{avgdl}})}, \quad \text{idf}_t = \ln \left(1 + \frac{N - \text{df}_t + 0,5}{\text{df}_t + 0,5} \right).$$

Duas decisões merecem destaque. (i) Usamos o idf com deslocamento ($1 + \dots$): sem ele, 16 termos muito frequentes (*of, the, and...*) teriam idf *negativo* na configuração **nada**, e um documento perderia pontos por conter um termo da consulta. (ii) k_1 e b são parâmetros de busca, não do índice: o índice guarda apenas tf, df e $|d|$, e o grid de parâmetros (Seção 4.4) não reconstrói nada.

A diferença conceitual central em relação ao Modelo Vetorial é a saturação da tf. Com $k_1 = 1,2$ (e $|d| = \text{avgdl}$), a contribuição de um termo vai de 1,000 (tf = 1) a 2,148 (tf = 50) e converge para $k_1 + 1 = 2,2$; o fator logarítmico do tf-idf no mesmo intervalo chega a 2,699 e continua crescendo. Além disso, o fator b controla *quanto* o comprimento do documento penaliza o score: $b = 0$ ignora o comprimento e $b = 1$ normaliza totalmente pelo desvio em relação ao comprimento médio.

3 Avaliação

Dataset. Coleção Cranfield, obtida pelo `ir_datasets` (identificador `cranfield`): 1400 resumos de artigos de aerodinâmica, 225 consultas em linguagem natural e 1837 julgamentos de relevância (qrels). Os graus são -1 e 1 a 4 , numa escala decrescente: $1 = \text{complete answer to the question}$ e $4 = \text{minimum interest}$ ($-1 = \text{references of no interest}$). A documentação do `ir_datasets` descreve a escala na ordem inversa; adotamos a direção original da coleção. Todas as consultas têm ao menos um documento relevante.

Relevância. Para as métricas binárias, é relevante todo documento com grau ≥ 1 ; grau -1 e documentos não julgados são não relevantes. Os qrels foram usados apenas na avaliação, nunca para construir ou ajustar rankings (ver a ressalva sobre a q13 na Seção 4.5).

Métricas. Precision@10 e Recall@10 (fração dos dez primeiros que é relevante e fração dos relevantes presente no Top-10); MAP, média sobre as consultas da precisão média (AP) calculada sobre o *ranking completo*; e NDCG@10 com relevância graduada. Como o grau 1 é o mais relevante, o ganho é linear e invertido, $5 - \text{grau}$ (grau 1 vale 4 e grau 4 vale 1), e o IDCG é calculado a partir dos julgamentos da própria consulta. As métricas binárias não dependem da direção da escala, pois relevante = grau ≥ 1 abrange os graus 1 a 4. Todas as métricas são guardadas por consulta e agregadas pela média.

Configurações experimentais. 2 modelos $\times$ 4 configurações de pré-processamento $\times$ 225 consultas (1800 linhas de métricas por consulta). Nos requisitos 5 a 9 fixamos a melhor configuração, **stop+stem**, e o BM25 com $k_1 = 1,2$ e $b = 0,75$, exceto no grid de parâmetros, que avalia $k_1 \in \{0,5; 1,2; 2,0\}$ e $b \in \{0; 0,75; 1\}$.

4 Resultados Obtidos e Análise

4.1 Avaliação quantitativa

A Tabela 2 traz as médias das oito combinações.

Tabela 2: Métricas agregadas (média sobre as 225 consultas), ordenadas por MAP.

Modelo	Configuração	P@10	R@10	MAP	NDCG@10
BM25	stop+stem	0,2356	0,3991	0,3050	0,3676
BM25	stemming	0,2276	0,3882	0,2951	0,3599
BM25	stopwords	0,2240	0,3801	0,2803	0,3439
Vetorial	stop+stem	0,2120	0,3681	0,2718	0,3285
BM25	nada	0,2164	0,3670	0,2694	0,3344
Vetorial	stemming	0,2027	0,3532	0,2589	0,3146
Vetorial	stopwords	0,1987	0,3368	0,2475	0,3022
Vetorial	nada	0,1933	0,3262	0,2396	0,2924

- O BM25 vence nas quatro métricas, em todas as configurações. O pior BM25 (MAP 0,2694) praticamente empata com o melhor Vetorial (0,2718): a escolha do modelo pesa tanto quanto o pré-processamento.
- A ordenação das configurações é idêntica nos dois modelos: **nada** < **stopwords** < **stemming** < **stop+stem**.
- O **stemming** contribui mais que as **stopwords** (no BM25, +9,5% contra +4,0% de MAP sobre **nada**). Isso confirma a Tabela 1: o idf já neutraliza termos ubíquos, então remover stopwords traz eficiência mais do que efetividade, enquanto unir variantes morfológicas cria casamentos que antes não existiam.
- $R@10 > P@10$ porque a maioria das consultas tem menos de dez relevantes; nesses casos o teto de P@10 já

é menor que 1.

As médias escondem grande variação entre consultas. A Tabela 3 resume a distribuição das 225 linhas por modelo (arquivo completo: `metricas_por_consulta.csv`).

Tabela 3: Resumo das métricas por consulta (`stop+stem`, 225 consultas).

Modelo	AP mediana	AP desvio-padrão	$AP \geq 0,5$	$AP = 0$	$P@10 = 0$	$P@10 = 0$ nos dois
Vetorial	0,204	0,221	42	3	39	
BM25	0,243	0,235	50	3	31	27

4.2 Comparação entre modelos

Com a configuração fixa em `stop+stem`, a comparação pareada por consulta mostra que o **BM25 ganha em 144 consultas, perde em 74 e empata em 7** (Figura 1, esquerda). Os rankings são de fato diferentes: em média só 6,48 dos 10 primeiros documentos são comuns aos dois modelos (mediana 6, mínimo 1).




Figura 1: Esquerda: AP de cada consulta nos dois modelos (acima da diagonal, BM25 melhor). Direita: posições ganhas pelo BM25 para cada par (consulta, documento relevante), por faixa de comprimento do documento (avgdl = 94,8).

Para entender *onde* ocorrem as diferenças, analisamos $\Delta AP = AP_{BM25} - AP_{Vet}$ por consulta. Três evidências apontam para o comprimento dos documentos:

- **Correlação com características da consulta.** Das três características testadas, só o **comprimento médio dos documentos relevantes** está associado a ΔAP ($r = 0,374$). O tamanho da consulta ($r = -0,067$) e o número de relevantes ($r = -0,069$) praticamente não têm relação.
- **Ganho de posição por comprimento.** Nos 1612 pares (consulta, documento relevante), as posições ganhas pelo BM25 crescem de forma monotônica com o comprimento do documento: o BM25 *perde* 14,1 posições em documentos com menos de 60 termos e *ganha* 29,4 em documentos com mais de 160 (Figura 1, direita).
- **Presença no Top-10.** Relevantes com mais de 120 termos aparecem 157 vezes no Top-10 do BM25 e 105 no do Vetorial. Com menos de 60 termos a relação se inverte: 128 no BM25 contra 158 no Vetorial.

Hipótese: a diferença está na normalização por comprimento. O cosseno divide o score por $\|\vec{d}\|$, que cresce com *todos* os termos do documento. Assim, um documento longo é penalizado mesmo quando é longo por tratar o assunto a fundo. No BM25, com $b = 0,75$, só 75% do desvio em relação ao avgdl é descontado, e esse desconto age sobre uma tf já saturada, que não recompensa documentos longos apenas por repetirem termos.

4.3 Análise por consulta

As consultas foram escolhidas automaticamente pelo ΔAP , sem seleção manual. A Tabela 4 mostra o Top-5 de cada modelo.

(i) **BM25 superior: consultas 167 e 36.** Na q167 (*ablative mass loss ... hypersonic flight*) os dois relevantes têm 142 e 195 termos, bem acima do avgdl. O BM25 coloca o doc 274 em 1º e o doc 82 em 4º; o Vetorial só alcança o doc 274 na 4ª posição, e seu topo é ocupado por documentos de 98, 92 e 43 termos, menos penalizados pela divisão pela norma. Na q36 o efeito é mais forte: o BM25 traz o doc 168 (140 termos) em 1º, enquanto o Vetorial não tem *nenhum* relevante no Top-5.

(ii) **Vetorial superior: consultas 17 e 190.** É a situação inversa. O relevante da q17 tem apenas 37

Tabela 4: Top-5 por consulta: $\text{id}(|d|)$, com relevantes em **negrito**. A última coluna traz o comprimento dos relevantes.

Consulta	Modelo	AP	Top-5	$ d $ relevantes
167	Vetorial	0,216	553 (98) · 1279 (92) · 1099 (43) · 274 (142) · 1100 (78)	142, 195
	BM25	0,750	274 (142) · 1279 (92) · 553 (98) · 82 (195) · 1098 (99)	
36	Vetorial	0,064	123 (140) · 281 (25) · 1299 (40) · 526 (71) · 1222 (120)	76, 140
	BM25	0,503	168 (140) · 123 (140) · 623 (118) · 518 (112) · 959 (120)	
17	Vetorial	0,513	106 (37) · 336 (49) · 326 (33) · 498 (86) · 1108 (148)	37, 92
	BM25	0,079	1108 (148) · 1281 (130) · 336 (49) · 700 (69) · 1301 (93)	
190	Vetorial	0,727	390 (75) · 391 (79) · 1008 (51) · 15 (74) · 627 (85)	29, 29, 74, 75, 79
	BM25	0,399	390 (75) · 627 (85) · 856 (142) · 15 (74) · 1339 (134)	
13	Vetorial	0,000	496 (69) · 903 (123) · 520 (135) · 313 (34) · 643 (79)	49, 49, 91, 107
	BM25	0,000	496 (69) · 903 (123) · 520 (135) · 313 (34) · 440 (57)	
22	Vetorial	0,000	153 (32) · 207 (101) · 125 (134) · 254 (34) · 348 (98)	65
	BM25	0,000	125 (134) · 560 (129) · 50 (98) · 81 (68) · 413 (87)	

termos e o Vetorial o põe em 1º; no BM25 ele sai do Top-5, que começa por documentos de 148 e 130 termos e não tem relevante algum. Na q190 os cinco relevantes são curtos (29 a 79 termos), e o BM25 os troca por documentos de 134 e 142 termos. A **simetria entre (i) e (ii)** é a evidência mais forte de que a diferença vem da normalização por comprimento, e não de uma superioridade genérica de um dos modelos.

(iii) **Ambos insatisfatórios: consultas 13 e 22.** Das 27 consultas com $P@10 = 0$ nos dois modelos, estas são as duas piores, com AP exatamente 0. O diagnóstico é descasamento de vocabulário: nenhum documento relevante compartilha *um único termo* com a consulta. Na q13 (*transonic aileron buzz*) os relevantes falam em *shock wave*, *buffeting* e *vorticity*; na q22, dois termos da consulta (**anyon**, **els**) sequer existem na coleção. Com interseção vazia o score é zero por construção, e nenhuma ponderação resolve.

4.4 Variação dos parâmetros do BM25




Figura 2: MAP e NDCG@10 do BM25 (**stop+stem**) para o grid $k_1 \times b$.

Tabela 5: Grid de parâmetros do BM25: MAP / NDCG@10. Em destaque, o melhor ponto; em *itálico*, o padrão.

$k_1 \backslash b$	0,00	0,75	1,00
0,5	0,2668 / 0,3224	0,2902 / 0,3475	0,2925 / 0,3506
1,2	0,2756 / 0,3337	<i>0,3050 / 0,3676</i>	0,3010 / 0,3663
2,0	0,2798 / 0,3371	0,3106 / 0,3734	0,3066 / 0,3670

A Figura 2 e a Tabela 5 mostram que as duas métricas concordam: o melhor ponto é $k_1 = 2,0$, $b = 0,75$ em ambas, e a ordenação das nove células é praticamente a mesma.

- b tem mais efeito que k_1 : passar b de 0 para 0,75 (com $k_1 = 1,2$) rende +10,7% de MAP; variar k_1 de 0,5 para 2,0 (com $b = 0,75$) rende +7,0%.
- $b = 0$ é a única escolha claramente ruim. De 0 para 0,75 o ganho é grande; de 0,75 para 1 há uma leve *perda* (exceto com $k_1 = 0,5$). Alguma normalização por comprimento é essencial, mas a normalização total é excessiva, o que é coerente com a Seção 4.2: o Vetorial, que sempre normaliza pela norma completa, perde justamente nos documentos longos.
- $k_1 = 2,0$ vence nas três colunas. Saturar mais devagar favorece esta coleção de resumos técnicos curtos, nos quais repetir um termo indica o assunto do texto, e não enchimento.
- O melhor ponto rende apenas +1,8% sobre o padrão; mantivemos $k_1 = 1,2$ e $b = 0,75$ nos demais experimentos.

Consulta em que b muda o ranking: q161 (*integral method ... laminar separation point*). Entre $b = 0$ e $b = 1$ só 3 dos 10 primeiros documentos são comuns. Com $b = 0$, os documentos 329, 962 e 364 (376, 232 e 214 termos, nenhum relevante) ocupam as posições 3 a 5, e o Top-5 tem em média 218 termos. Com $b = 0,75$ ou 1 eles saem, o comprimento médio do Top-5 cai para 95 termos ($\approx \text{avgdl}$), o relevante doc 55 (81 termos) entra em 3º e o AP@10 sobe de 0,417 para 0,500. Isso confirma, *manipulando o parâmetro*, o que as Seções 4.2 e 4.3 observaram.

4.5 Modificação de consultas

Reformulamos cinco consultas a partir do texto da consulta e de conhecimento de domínio e executamos as versões original e modificada nos dois modelos (Tabela 6).

Tabela 6: Reformulações (**stop+stem**). Métricas no formato original $\rightarrow$ modificada; “troc.” = documentos trocados no Top-10 (Vetorial / BM25).

Q	Consulta modificada (tipo)	P@10		NDCG@10		troc.
		Vetorial	BM25	Vetorial	BM25	
22	<i>turbulent skin friction viscosity variation with temperature</i> (remoção de termos não-conteúdo)	0,0 $\rightarrow$ 0,0	0,0 $\rightarrow$ 0,0	0,000 $\rightarrow$ 0,000	0,000 $\rightarrow$ 0,000	3 / 1
13	<i>transonic aileron buzz shock wave boundary layer interaction control surface oscillation</i> (acrécimo)	0,0 $\rightarrow$ 0,1	0,0 $\rightarrow$ 0,1	0,000 $\rightarrow$ 0,184	0,000 $\rightarrow$ 0,199	6 / 7
82	<i>methods for calculating lift distribution on swept wings in subsonic flow</i> (remoção de nomes próprios)	0,2 $\rightarrow$ 0,2	0,3 $\rightarrow$ 0,2	0,517 $\rightarrow$ 0,517	0,540 $\rightarrow$ 0,275	2 / 3
200	<i>buckling stresses in torispherical shells</i> (mais genérica)	0,1 $\rightarrow$ 0,1	0,2 $\rightarrow$ 0,1	0,235 $\rightarrow$ 0,296	0,370 $\rightarrow$ 0,296	6 / 6
95	<i>theoretical heat transfer distribution around a hemisphere blunt nosed body stagnation point</i> (mais específica)	0,1 $\rightarrow$ 0,1	0,2 $\rightarrow$ 0,2	0,065 $\rightarrow$ 0,272	0,416 $\rightarrow$ 0,411	6 / 4

Reformular muda muito o ranking, mas o efeito médio é pequeno e instável. Em média 4,4 dos 10 documentos do Top-10 são trocados. O P@10 médio fica igual (0,110 $\rightarrow$ 0,110) por compensação: a q13 ganha um relevante nos dois modelos, enquanto o BM25 perde um na q82 e outro na q200. O NDCG@10 médio sobe de 0,214 para 0,245, mas o ganho vem quase todo de dois casos: a q13, que passa a recuperar um relevante, e o Vetorial na q95; sem eles, a média cairia. Dos 10 casos, 4 melhoram, 3 pioram e 3 ficam iguais em NDCG@10: é uma intervenção de alta variância, cujo efeito depende da consulta e do modelo. A dependência do modelo é clara: generalizar a q200 melhora o Vetorial e piora o BM25, e especificar a q95 melhora muito o Vetorial (0,065 $\rightarrow$ 0,272) e deixa o BM25 praticamente parado. A reformulação manual interage com o modelo e não é uma melhoria independente dele.

- **q13 sai do zero.** O acréscimo de *shock wave*, *boundary layer* e *interaction* cria a interseção que faltava, e o relevante doc 265 entra no Top-10 dos dois modelos (5º no BM25). Isso confirma na prática o diagnóstico da Seção 4.3: quando a falha é de vocabulário, só mudar a representação da consulta resolve. Mas a expansão também trouxe dois documentos vizinhos não relevantes (335 e 798, sobre interação choque-camada limite). *Ressalva:* os termos acrescentados se justificam pela física (o *buzz* transônico é causado pela interação entre onda de choque e camada limite), mas coincidem com o vocabulário que o diagnóstico da Seção 4.3 encontrou nos relevantes. Por isso, este ganho não é uma evidência independente dos qrels.
- **q22 continua em zero.** Retirar os termos conversacionais eliminou ruído, mas não *acrescentou* nenhum termo do relevante. Remover ruído não é o mesmo que expandir o vocabulário.
- **q82 é o fracasso instrutivo.** Remover os nomes de autores derrubou o NDCG@10 do BM25 de 0,540 para 0,275. O termo *kuchemann* tem $df = 1$ ($idf = 6,84$) e apontava exatamente para o artigo relevante 678, que cai de 1º para 3º (*multhopp* nem existe na coleção). O que parecia ruído era o sinal mais forte da consulta.

4.6 Análise de erros

Os casos foram selecionados por critério programático sobre o BM25 (**stop+stem**): para os não relevantes no topo, documentos de grau -1 em 1º lugar; para o relevante fora do Top-10, o documento de grau 1 (resposta completa, a falha mais grave possível) com a pior posição.

Não relevante em 1º – q7, doc 492 (score 64,08, o maior entre os erros desse tipo). A consulta pede *pressure distributions for an ogive forebody at angle of attack*; o título do documento é *prediction of ogive-forebody pressures at angles of attack*. A decomposição do score mostra por que ele é tão alto: dois termos raríssimos, *ogiv* ($df = 14$, $idf = 4,57$, contribuição 15,3) e *forebodi* ($df = 8$, $idf = 5,10$, contribuição 17,1), somados a $tf = 4$ em *pressur*, *angl* e *attack* num documento curto de 34 termos, que o fator b favorece. Alto idf e alta tf ao mesmo tempo, e mesmo assim o documento é julgado com grau -1 .

Não relevante em 1º – q13, doc 496, nos dois modelos. O termo *buzz* tem $df = 1$ e $idf = 6,84$: existe em um único documento da coleção, justamente este (*a theory of transonic aileron buzz*), e sozinho garante a primeira posição. Também é julgado com grau -1 .

O padrão por trás dos dois casos. Cada consulta tem exatamente um documento de grau -1 , e ele fica sistematicamente no topo: em 1º lugar em 96 das 225 consultas no BM25 (43%) e em 81 no Vetorial (36%); no Top-10 em 72% e 69%, respectivamente (posição mediana 2 e 3). Há também indícios estruturais: o id desse documento tem correlação de 0,662 com o número da consulta, e consultas consecutivas compartilham o mesmo documento ($q1/q2 \rightarrow 486$, $q7/q8 \rightarrow 492$, $q13/q14 \rightarrow 496$). A explicação mais provável é que o documento de grau -1 seja o artigo a partir do qual a consulta foi formulada. Isso explica o casamento lexical quase perfeito e a numeração correlacionada, e o julgamento “*references of no interest*” faz sentido para quem já conhece o artigo. Consequência: em 43% das consultas o melhor resultado do BM25 conta como erro *por construção da coleção*, o que impõe um teto à $P@10$ que não vem de falha de modelagem.

Relevante fora do Top-10 – q176, doc 583 (grau 1, posição 939 de ~1400). A consulta é *some approximate analytical heat conduction solutions using methods other than biot’s principle*; o documento, *influence coefficients for real gases*, é julgado como resposta completa. Dos 9 termos da consulta ele compartilha só um: *use*, um verbo genérico ($idf = 1,00$), sem poder discriminativo. É o oposto dos casos anteriores: casamento lexical quase nulo e relevância máxima. O julgamento se apoia no conteúdo conceitual do artigo, não no vocabulário, e nenhum modelo baseado em sobreposição de termos consegue recuperá-lo.

5 Considerações Finais

1. **A normalização por comprimento é o que separa os dois modelos.** A correlação com ΔAP ($r = 0,374$), o ganho por faixa de comprimento (+29,4 posições para relevantes longos), a simetria dos casos individuais e o experimento com b apontam para a mesma causa. O Modelo Vetorial é um extremo rígido dessa escala: normaliza sempre pela norma completa, sem um parâmetro que possa relaxar a normalização.
2. **O descasamento de vocabulário é o teto dos dois modelos.** Ambos pontuam por sobreposição ponderada de termos; com interseção vazia o score é zero, e nenhum ajuste de ponderação, k_1 ou b muda isso. Só mudar a representação da consulta funciona, e mesmo assim de forma imprecisa (q13). O caminho robusto seria uma representação semântica (expansão de consulta, embeddings).
3. **Termos de df muito baixo são apostas de alto risco.** O idf os torna decisivos nos dois sentidos: *kuchemann* ($df = 1$) era o melhor sinal da q82, e *buzz* ($df = 1$) sozinho pôs um não relevante em 1º na q13.
4. **Hierarquia dos ganhos de MAP:** pré-processamento (*nada* $\rightarrow$ *stop+stem*, BM25) **+13,2%**; modelo (Vetorial $\rightarrow$ BM25, *stop+stem*) **+12,2%**; ajuste de parâmetros do BM25 (padrão $\rightarrow$ melhor ponto) **+1,8%**. Pré-processamento e escolha do modelo valem uma ordem de grandeza a mais que o ajuste fino, e os valores convencionais $k_1 = 1,2$, $b = 0,75$ já são adequados para esta coleção.

6 Uso de ferramentas de IA

Utilizamos o assistente Claude (Anthropic) como apoio na redação e formatação deste relatório em Latex, a partir dos resultados e das análises produzidos pelo grupo no notebook. Em relação ao código do projeto, utilizamos a IA para auxiliar a escrever algumas partes do código que estávamos em dúvida, a depurar o código e na revisão de respostas.